DOSSIER D'ARCHITECTURE & SPÉCIFICATIONS TECHNIQUES

Intelligent Document Extractor

Documentation Technique Complète, Justification de la Stack et Architecture Système

Projet : Intelligent Document Extractor	**Environnement :** Full-Stack (Render / Atlas)
Auteur / Propriétaire : Équipe Ingénierie	**Généré le :** 20/10/2026
Stack Principale : FastAPI, React 19, MongoDB Atlas	**IA & Vision :** Tesseract, OpenCV, MediaPipe, OpenRouter

Résumé Exécutif

Ce document constitue le dossier de référence officiel de la plateforme **Intelligent Document Extractor**. L'application a été conçue pour résoudre trois défis majeurs des systèmes d'information modernes : (1) l'automatisation intégrale de l'ingestion comptable (extraction structurée de factures multidevises via OCR et LLM), (2) la sécurisation biométrique des accès utilisateurs avec authentification faciale anti-usurpation (*Liveness Detection*), et (3) la vérification d'identité KYC (*Know Your Customer*) combinant analyse de carte nationale d'identité et audit d'administration.

Chaque brique logicielle, bibliothèque et composant d'intelligence artificielle a été sélectionné selon des critères rigoureux d'efficience algorithmique, de robustesse cryptographique, de légèreté mémoire et de conformité aux standards industriels.

1. Architecture Globale du Système

L'application s'appuie sur une architecture distribuée moderne découplée en trois couches : une interface client réactive (Frontend SPA), un serveur d'application d'inférence asynchrone (Backend REST), et une couche de persistance hybride (Base NoSQL + Stockage sécurisé isolé).

Couche	Technologies Clés	Rôle & Responsabilité Système
Frontend (Client)	React 19, Vite 8, Recharts, CSS Glassmorphism	Interface monopage (SPA) réactive, capture flux WebCam HTML5, dashboard analytique, lecteur TTS.
Backend (API)	FastAPI, Uvicorn, Gunicorn, Pydantic v2	Passerelle ASGI asynchrone, validation stricte, endpoints REST, sécurisation des sessions JWT.
Vision & OCR	Tesseract OCR, Poppler (pdf2image), OpenCV (CLAHE)	Binarisation, débruitage, rehaussement de contraste, conversion PDF vectoriel vers matriciel, OCR bilingue.
Biométrie Faciale	YuNet ONNX, SFace ONNX, Cosine Similarity	Détection faciale ultra-rapide, extraction de gabarit facial (vecteur 128D) et calcul d'appariement.
Anti-Usurpation	MediaPipe Face Landmarker (478 repères 3D)	Mesure de l'Eye Aspect Ratio (EAR) pour le clignement des yeux et validation des rotations de tête.
Intelligence LLM	OpenRouter (GPT-3.5-Turbo, GPT-4o-mini)	Structuration JSON déterministe des factures et assistant conversationnel bilingue FR/AR.
Synthèse Vocale	ElevenLabs TTS via OpenRouter Audio	Restitution vocale naturelle et fluide des réponses du chatbot en streaming binaire MP3.
Base de Données	MongoDB Atlas, PyMongo, DnsPython	Base NoSQL cloud flexible pour stocker les factures et les profils utilisateurs avec index uniques.
Stockage Privé	Système de fichiers avec protection Path Traversal	Coffre-fort local isolé pour les images CNI et selfies avec en-têtes no-cache stricts.

2. Backend & Serveur d'Application : Choix & Justifications

FastAPI : Sélectionné pour sa compatibilité native avec l'asynchronisme Python (`async/await`), essentiel lors de la manipulation de fichiers volumineux et d'appels réseau distants (LLM, MongoDB Atlas). Ses performances figurent parmi les plus élevées de l'écosystème Python grâce à Starlette et Pydantic.

Uvicorn & Gunicorn : Uvicorn assure le rôle de serveur ASGI ultra-léger basé sur `uvloop`. En production (déploiement Render Linux), Gunicorn agit comme superviseur de processus maître (process manager), garantissant la haute disponibilité, le redémarrage automatique en cas de défaillance et l'équilibrage de charge entre workers.

Python-Multipart : Obligatoire sous FastAPI pour parser les requêtes `multipart/form-data`, permettant de recevoir simultanément des métadonnées (formulaires) et des flux binaires de fichiers (PDF, JPEG, PNG, séquences d'images).

Pydantic v2 & Email-Validator : Garantit l'intégrité absolue des flux entrants et sortants. La validation Pydantic élimine les failles d'injection de types et normalise la sérialisation JSON. `email-validator` applique les règles RFC pour interdire toute adresse email frauduleuse ou malformée.

PyMongo & DnsPython : Pilote officiel MongoDB. Le flag `[srv]` et `dnspython` permettent la résolution transparente des clusters répliqués MongoDB Atlas via les URIs modernes `mongodb+srv://`.

3. Pipeline OCR & Vision par Ordinateur

Le traitement documentaire suit une chaîne de traitement séquentielle optimisée pour transformer des documents hétérogènes (factures scannées, photos de téléphone, PDF natifs) en informations numériques exploitables.

Traitement Documentaire & OCR

- **Tesseract OCR (pytesseract) :** Moteur de reconnaissance optique de caractères développé par HP et perfectionné par Google. Il fonctionne en local sur le serveur, garantissant la gratuité et la conformité avec la confidentialité des données financières. Il est configuré en mode bilingue (`lang='fra+eng'`) pour capturer les vocabulaires comptables français et internationaux.
- **Poppler & pdf2image :** Tesseract ne sachant pas interpréter la structure vectorielle des fichiers PDF, `pdf2image` s'interface avec le binaire Poppler (`pdftoppm`) pour pixelliser chaque page à 300 DPI (résolution optimale recommandée pour la détection fine des petits caractères de facture).
- **OpenCV Headless (CLAHE & Filtre Bilatéral) :** Avant d'appliquer l'OCR sur des cartes d'identité, l'image subit un prétraitement : agrandissement cubique (x2), conversion en niveaux de gris, lissage par filtre bilatéral (réduction du bruit sans flouter les arêtes) et égalisation adaptative d'histogramme (CLAHE) pour surmonter les reflets et les zones sombres.

Extraction Intelligente par LLM (OpenRouter)

L'OCR brut contient fréquemment des imperfections (tableaux éclatés, sauts de lignes anarchiques, coquilles de caractères). Plutôt que d'utiliser des expressions régulières fragiles, le projet intègre un modèle de langage (LLM) via **OpenRouter** :

1. **Format Déterministe :** Activation de `response_format={'type': 'json_object'}` forçant l'IA à produire un JSON valide.
2. **Normalisation Métier :** Prise en compte explicite des spécificités françaises et algériennes : suppression des espaces séparateurs de milliers, remplacement de la virgule décimale par le point, conversion normalisée de la devise ('DA' devient 'DZD').
3. **Validation Pydantic :** Le résultat JSON retourné est instancié dans le modèle `InvoiceData`, garantissant l'absence de champs inattendus et la conformité des types numériques (float).

4. Biométrie Faciale & Détection du Vivant (Liveness)

Pour concilier sécurité et fluidité d'expérience, l'application intègre un module biométrique avancé exécuté intégralement en mémoire vive (aucune image sensible n'est persistée lors des vérifications de connexion).

Composant	Modèle / Algorithme	Principe & Rôle dans l'Application
Détecteur de Visage	YuNet ONNX (OpenCV FaceDetectorYN)	Localise les boîtes englobantes et 5 repères faciaux clés. Rejette les photos sans visage ou à visages multiples.
Extracteur de Traits	SFace ONNX (OpenCV FaceRecognizerSF)	Aligne le visage et produit un gabarit numérique (vecteur d'embedding 128D) invariant à l'éclairage.
Score d'Appariement	Similarité Cosinus (Seuil opérationnel 0.40)	Calcule la proximité angulaire entre l'empreinte faciale enregistrée et le selfie présenté.
Clignement des Yeux	MediaPipe Face Landmarker (Eye Aspect Ratio - EAR)	Mesure la fermeture dynamique des yeux (transition Ouvert -> Fermé -> Ouvert) pour stopper les attaques par photo.
Mouvement de Tête	MediaPipe 3D Landmarks (Position relative du nez)	Vérifie une rotation horizontale du visage par rapport à l'axe des yeux.
Sélection de Trame	Variance du Laplacien & Surface	Sélectionne automatiquement l'image la plus nette et la mieux cadrée parmi la rafale vidéo.

5. Sécurité, Chiffrement & Workflow KYC

La manipulation de pièces d'identité et d'empreintes biométriques exige le respect strict des réglementations sur les données personnelles (RGPD).

Gestion des Mots de Passe & Sessions

- **Argon2id (pwdlib) :** Le hachage des mots de passe emploie Argon2id, standard cryptographique supérieur à bcrypt. Les mots de passe ne transitent et ne sont stockés qu'après dérivation à mémoire dure, empêchant le cassage par dictionnaires massifs ou cartes graphiques.
- **Tokens JWT Signés (PyJWT) :** Les sessions sont gérées sans état avec une expiration configurée à 8 heures. Chaque token intègre l'identifiant utilisateur (`sub`), l'adresse email et l'horodatage d'émission (`iat`).

Stockage Sécurisé & Protection des Données KYC

- **Répertoire Isolé :** Les photos de cartes d'identité et les selfies KYC sont enregistrés dans `private_identity_documents/`, un répertoire situé hors de portée du serveur web statique public.
- **Noms de Fichiers Obfusqués :** Les fichiers sont renommés de manière unique et aléatoire via UUIDv4 (`{user_id}_{document_id}_id.jpg`), rendant toute devinette ou énumération d'URL impossible.
- **Protection Anti-Path Traversal :** Avant toute lecture, le serveur résout le chemin absolu et vérifie `file_path.is_relative_to(PRIVATE_DIR)`, neutralisant toute tentative d'injection de caractères spéciaux (`../`).
- **En-têtes HTTP de Confidentialité :** Lors de la consultation par un administrateur, les documents sont servis avec les directives `Cache-Control: private, no-store, no-cache, max-age=0` et `X-Content-Type-Options: nosniff`, interdisant le stockage temporaire sur les serveurs mandataires ou le navigateur.

Workflow d'Administration & Revue Manuelle

Le système n'adopte pas une validation d'identité 100% aveugle. Il utilise le concept d'**aide à la décision** : le moteur calcule un score de similarité faciale et extrait les informations textuelles de la carte, mais place systématiquement le dossier au statut `review_required`. Un administrateur habilité (contrôlé par `require_admin` et la variable d'environnement `ADMIN_EMAILS`) examine visuellement les pièces, annote le dossier et émet la décision finale (`verified` ou `rejected`).

6. Exports Comptables & Reporting Automatisé

Pour s'intégrer aux processus d'entreprise, l'application propose deux canaux d'exportation programmatique :

- **OpenPyXL (Export Excel .xlsx) :** Génère un classeur structuré avec en-têtes bleus stylisés, police blanche grasse, largeur de colonnes calculée dynamiquement selon la longueur du contenu, filtres automatiques activés et gel de la ligne supérieure de titre.
- **ReportLab Platypus (Export PDF Comptable) :** Compile un document récapitulatif officiel en orientation paysage (`landscape(A4)`). La pagination, le positionnement des totaux et la mise en page sont générés en flux mémoire (`BytesIO`) et streamés au client.

7. Frontend : Interface Utilisateur & Composants

Le client web est conçu sous la forme d'une application monopage (SPA) alliant légèreté, esthétique moderne et réactivité temps réel.

Technologies Fondatrices

- **React 19 :** Utilisation des dernières avancées de React pour la gestion déclarative de l'état (hooks `useState`, `useEffect`, `useRef`). Permet un rendu fluide des différentes vues sans rechargement de page.
- **Vite 8 :** Remplace Create-React-App et Webpack. Offre un démarrage du serveur de développement à froid en quelques millisecondes grâce aux modules ES natifs, ainsi qu'un bundling de production hautement optimisé via Rollup.
- **Recharts :** Bibliothèque de graphiques SVG composables pour React. Intégrée dans le composant Dashboard pour afficher la répartition des montants (HT, TVA, TTC) et les volumes de factures traitées par période.
- **Design Glassmorphism & Vanilla CSS :** L'esthétique visuelle repose sur un thème sombre haut de gamme, utilisant des effets de flou (`backdrop-filter: blur`), des bordures subtiles et des transitions CSS soignées sans dépendance lourde tierce.
- **API WebCam Native (HTML5 Canvas) :** Pilotage direct de la caméra via `navigator.mediaDevices.getUserMedia`, permettant la capture instantanée de clichés et de séquences de clignotement sans recourir à des bibliothèques externes encombrantes.

Structure Modulaire des Composants Frontend

Composant React	Fichier Source	Rôle & Fonctionnalités Clés
App.jsx	src/App.jsx	Routeur interne, restauration de session JWT, gestion des onglets et état global de l'application.
AuthGateway	src/components/AuthGateway.jsx	Portail de connexion/inscription combinant saisie identifiants et authentification faciale avec caméra.
IdentitySubmission	src/components/IdentitySubmission.jsx	Téléversement de la CNI et enregistrement guidé du selfie en direct pour constitution du dossier KYC.
AdminDocumentReview	src/components/AdminDocumentReview.jsx	Interface d'audit administrateur : inspection visuelle CNI vs Selfie, filtres par statut, validation/rejet.
Dashboard	src/components/Dashboard.jsx	Affichage des KPIs financiers globaux et graphiques analytiques interactifs Recharts.
InvoiceResult	src/components/InvoiceResult.jsx	Visualisation détaillée des champs extraits de la facture avec possibilité de correction immédiate.
InvoiceHistory	src/components/InvoiceHistory.jsx	Tableau récapitulatif avec recherche textuelle, pagination, suppression et téléchargements Excel/PDF.
ChatWidget	src/components/ChatWidget.jsx	Bulle d'assistance flottante interactive avec historique de discussion et lecteur audio TTS intégré.

8. Assistant Conversationnel Bilingue & Synthèse Vocale

Un assistant virtuel intelligent a été intégré dans l'application pour guider les utilisateurs et administrateurs :

- **Bilinguisme Automatique (FR / AR) :** Le prompt système détecte la langue du message utilisateur et formule sa réponse en français ou en arabe selon le cas, tout en respectant une tonalité professionnelle et bienveillante.
- **Conscience du Rôle Utilisateur :** Si l'utilisateur est authentifié en tant qu'administrateur, le contexte système s'enrichit d'instructions spécifiques pour le guider sur la validation des dossiers d'identité et les statistiques financières.

- **Synthèse Vocale ElevenLabs (TTS) :** L'endpoint `/chat/tts` convertit les réponses textuelles en voix humaine naturelle diffusée sous forme de flux audio MP3 continu, offrant une accessibilité complète.

9. Déploiement & Compatibilité Multiplateforme

Le code du projet a été spécifiquement conçu pour fonctionner de manière transparente en environnement local de développement (Windows) et sur conteneur de production Cloud (Linux / Render) :

- **Détection Dynamique de Tesseract :** Dans `ocr.py`, le chemin vers l'exécutable Tesseract vérifie successivement la variable `TESSERACT_CMD`, le répertoire standard Windows (`C:\Program Files\Tesseract-OCR`), ou laisse le système Linux utiliser le binaire global `/usr/bin/tesseract` présent dans le PATH.
- **Résolution Hybride de Poppler :** Même mécanisme pour la bibliothèque Poppler (`POPPLER_PATH`), permettant une exécution fluide sous Windows via téléchargement autonome et sous Linux via les paquets natifs du système.
- **OpenCV Headless :** L'emploi du paquet `opencv-python-headless` élimine toute dépendance envers les bibliothèques graphiques X11 (libGL, Qt), prévenant les erreurs de segmentation courantes sur les serveurs conteneurisés.

10. Tableau Exhaustif de la Stack Technologique

Technologie	Version / Package	Domaine d'Application	Pourquoi cet outil a été choisi
FastAPI	0.110+	Backend API REST	Asynchronisme natif, vitesse d'exécution extrême, documentation OpenAPI automatique.
Uvicorn / Gunicorn	0.28+ / 21.2+	Serveur ASGI Prod	Exécution asynchrone haute cadence et supervision multi-workers en production.
MongoDB Atlas	PyMongo 4.6+	Base de données	Flexibilité NoSQL pour schémas de factures variables, haute disponibilité cloud.
Argon2id	pwdlib[argon2]	Sécurité Mots de passe	Standard cryptographique maximal (PHC Winner), résistance aux attaques GPU.
PyJWT	2.8+	Gestion des Sessions	Authentification sans état sécurisée via Bearer Tokens signés HMAC-SHA256.
Tesseract OCR	pytesseract 0.3.10	Extraction de texte	Moteur OCR open source réputé, bilingue français/anglais, exécution locale gratuite.
Poppler	pdf2image 1.17+	Rendu PDF	Conversion haute fidélité des PDF en images matricielles (300 DPI) pour l'OCR.
OpenCV	4.9+ (headless)	Vision par Ordinateur	Prétraitement d'images (CLAHE) et moteur d'inférence pour modèles de visages ONNX.
YuNet & SFace	ONNX Models	Biométrie Faciale	Détection faciale ultra-légère et comparaison d'empreintes faciales 128D par cosinus.
MediaPipe	0.10.10+	Anti-Usurpation / Liveness	Maillage facial 3D, détection du clignement d'yeux (EAR) et des mouvements de tête.
OpenRouter / GPT	OpenAI SDK 1.20+	Intelligence LLM	Structuration JSON déterministe des factures et assistant conversationnel bilingue.
ElevenLabs	TTS API	Synthèse Vocale	Rendu vocal humain haute fidélité pour les réponses du chatbot d'assistance.
OpenPyXL / ReportLab	3.1+ / 4.1+	Exports Comptables	Génération dynamique de tableurs Excel (.xlsx) et de rapports PDF en streaming mémoire.
React 19 & Vite 8	19.2+ / 8.3+	Interface Web SPA	Composants déclaratifs réactifs, HMR instantané et bundle de production ultra-léger.
Recharts	3.10+	Graphiques Analytics	Visualisation financière interactive vectorielle (SVG) pour le tableau de bord.

Fin du Document de Spécifications Techniques.